Arquitetura do Aprova.AI — EDA + CQRS

Este documento é a fonte de verdade da arquitetura do Aprova.AI e das regras de organização de diretórios. `docs/ARQUITETURA.pdf` é gerado a partir dele e deve ser regenerado a cada alteração (ver §13).

O Aprova.AI é um aplicativo para Android e iOS, feito com Expo e TypeScript, para estudo para o Enem, a Fuvest e outros vestibulares, com correção e apoio por IA (GPT 6.1 - Terra).

Sumário

1. Objetivo e escopo
2. Decisões arquiteturais
3. Visão geral
4. CQRS: comandos e consultas
5. EDA: eventos
6. Mensageria: BullMQ + Redis
7. Workers e integração com a IA
8. Fluxos principais
9. Aplicativo móvel
10. Organização de diretórios
11. Resiliência e segurança
12. Testes e validação
13. Governança dos documentos
14. Decisões em aberto
15. Guias de implementação

1. Objetivo e escopo

O objetivo é garantir que o app não trave e que nenhuma atividade em segundo plano se perca. Para isso, o que o aluno faz na tela (comandos) é desacoplado do que o sistema processa nos bastidores (consultas e IA).

Este documento define:

- a arquitetura geral (Event-Driven Architecture + CQRS) e seus contratos de alto nível;
- as regras de organização de diretórios e a refatoração aplicada ao repositório;
- as decisões em aberto que dependem de aprovação (§14).

Este documento não implementa funcionalidades, não adiciona dependências e não define a rubrica de correção de redações. Autenticação, banco de dados, canal de eventos e demais escolhas de tecnologia são propostos nos guias de implementação (§15) e só valem depois de aprovados (§14).

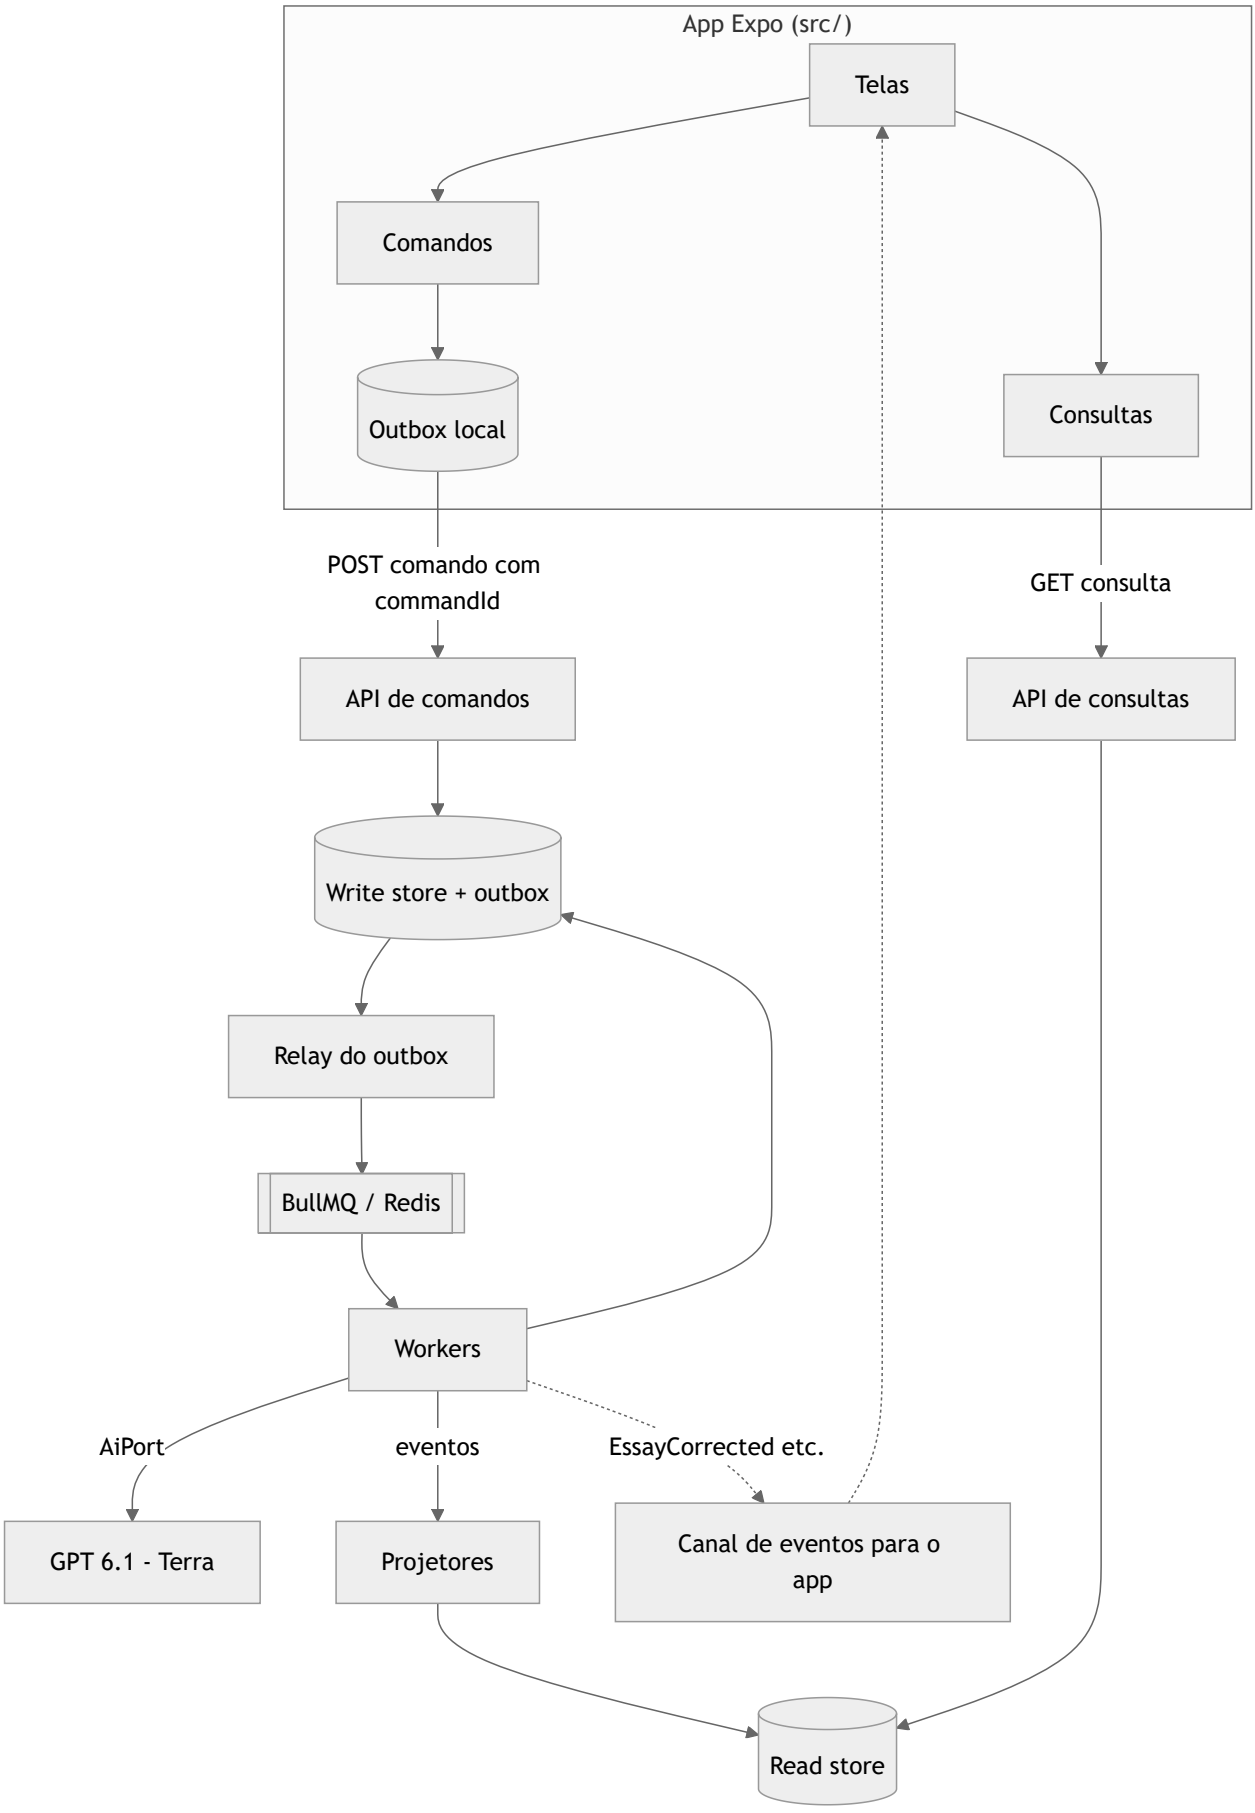
Estado de partida (verificado em `package.json` e no código): Expo `~57.0.24`, React Native `0.86.3`, React `19.2.3` e TypeScript `~6.0.3` em modo estrito. Não há roteador, cliente de rede, persistência, gerenciador de estado nem scripts de lint, testes ou verificação de tipos. O código existente é uma tela vazia em `src/app/App.tsx`.

2. Decisões arquiteturais

Id	Decisão	Motivo
D1	Arquitetura geral: EDA + CQRS.	Isolar a interação do aluno do processamento pesado e escalar leitura e escrita de forma independente.
D2	Fila padrão: BullMQ + Redis. SQS e RabbitMQ são alternativas atrás de uma porta única (`QueuePort`).	Backend em Node/TypeScript, com retries, backoff, jobs atrasados e limite de taxa para a IA, e pouca operação inicial.
D3	Comandos respondem de imediato (`202 Accepted`); o trabalho pesado roda em Workers.	Evita timeout da API e mantém o app responsivo (“Redação recebida com sucesso!”).
D4	O app mantém um outbox local e envia cada comando com chave de idempotência.	Nenhum comando se perde offline ou em falha de rede, e reenvios não duplicam efeitos.
D5	O servidor grava o estado e a mensagem de saída na mesma transação (outbox transacional) e um relay publica na fila.	Evita o estado inconsistente “gravou mas não enfileirou”.
D6	A IA só é chamada por Workers, atrás de `AiPort` .	Isola timeout, custo, limite de taxa e troca de provedor ou de modelo.
D7	Repositório único: app Expo na raiz, `backend/` e `contracts/` , sem workspaces nesta fase.	Evita mover o Expo e reconfigurar Metro, `app.json` e `tsconfig` antes de existir código de backend com dependências próprias.
D8	O lado de leitura é eventualmente consistente; a interface mostra estados explícitos de recebido, em processamento, concluído e falha.	A projeção é assíncrona; o aluno nunca vê um estado ambíguo.
D9	A correção de redação por IA é exclusiva de usuários com plano `PREMIUM` , limitada a 4 correções por mês; a regra é verificada no comando `SubmitEssay` antes do `202` .	Regra de produto e controle do único custo que cresce por usuário (a IA).
D10	Todo recurso de infraestrutura e de ferramenta deve ter opção gratuita; custo só entra com aprovação explícita, exceto a IA.	Regra do projeto; o custo recorrente fica restrito ao que o produto precisa.
D11	Hospedagem inicial na Oracle Cloud (Always Free) com Docker Compose; migração planejada para o Render (pago) quando a carga ou a operação exigirem.	Único caminho gratuito que atende aos requisitos do Redis do BullMQ (persistência AOF e `noeviction`).
D12	Lançamento em Android e iOS; as contas de desenvolvedor da Apple e do Google Play já existem e as licenças ficam fora do orçamento do projeto.	Decisão do responsável pelo produto.
D13	O domínio já existente (registrado na Hostinger) serve a API por um subdomínio (`api.`) apontado para o servidor.	Evita custo de domínio; HTTPS gratuito pelo servidor web do §10.

Alternativas consideradas para D7: monorepo com `apps/mobile` , `apps/api` e `apps/worker` (adiado: exige mover o Expo e alterar configuração de pacotes) e repositório separado para o backend (adiado: dificulta compartilhar `contracts/` e revisar mudanças de contrato em um único lugar). A migração para workspaces é compatível com esta estrutura.

3. Visão geral



- Lado de escrita: `UI → Comandos → Outbox local → API de comandos → Write store`.
- Lado de processamento: `Write store → Relay → BullMQ → Workers → IA / Projetores`.
- Lado de leitura: `UI → Consultas → API de consultas → Read store`.
- O canal de eventos para o app (push, polling ou SSE) está em aberto (§14); a arquitetura exige apenas que ele entregue eventos do §5.

4. CQRS: comandos e consultas

Conceito	Comando	Consulta	Evento
Significado	Intenção de mudar o estado.	Pedido de leitura.	Fato já ocorrido.
Nome	Verbo no imperativo: `SubmitEssay`.	`Get` + objeto: `GetPerformanceSummary`.	Passado: `EssaySubmitted`.
Efeito	Muda estado.	Nunca muda estado.	Imutável.
Resposta	`202 Accepted` com `commandId`; nunca o resultado do processamento.	DTO de um modelo de leitura.	Não há resposta.
Local	`application/commands`	`application/queries`	`application/events`

Lado de escrita

- Todo comando carrega `commandId` (UUID gerado no cliente), `issuedAt` (ISO 8601 UTC) e o `payload`. O `commandId` é a chave de idempotência: reenviar o mesmo comando devolve a mesma resposta e não repete o efeito.
- O handler valida o comando na borda, aplica as regras de `domain/`, grava o novo estado e a mensagem de saída na mesma transação e responde `202`.
- O write store é otimizado para gravações rápidas: inserções e atualizações simples, sem joins de leitura. A tecnologia está em aberto (§14).

Elegibilidade e cota da correção de redação (D9)

- Só usuários com plano `PREMIUM` ativo podem enviar redação para correção por IA. O handler de `SubmitEssay` consulta o plano por uma porta (`EntitlementPort`) e nunca confia em dado informado pelo app.
- O limite é de 4 correções por usuário por mês corrido, contado no fuso `America/Sao_Paulo` (premissa a confirmar com o produto, §14). A reserva da cota e a gravação da redação acontecem na mesma transação do comando.
- Sem plano Premium, o comando é rejeitado com `403` e o código `PREMIUM_REQUIRED`. Com a cota esgotada, a rejeição é `403` com `ESSAY_QUOTA_EXCEEDED`, `limit`, `used` e `resetsAt`. Nenhuma das duas consome cota nem cria job.
- Uma correção que termina em `EssayCorrectionFailed` permanente devolve a cota reservada, na mesma transação que grava a falha. Reenviar o mesmo `commandId` não reserva cota de novo.
- Como o usuário se torna Premium (assinatura e cobrança) está em aberto (§14); a arquitetura exige apenas que o plano seja consultável pela `EntitlementPort`.

Lado de leitura

- Consultas leem apenas modelos de leitura (projeções) desnormalizados e otimizados para leitura massiva: estatísticas de desempenho, gráficos de evolução e histórico de simulados.

- Toda resposta de consulta carrega `asOf` (instante da última projeção aplicada). A interface usa esse valor para indicar que o dado pode estar atrasado, em vez de apresentá-lo como definitivo.
- Handlers de consulta não importam `domain/` nem o write store.

Sincronização

Projetores (`application/events`) consomem eventos pela fila `projections` , atualizam o read store e registram a versão do agregado aplicada. Um evento com `aggregateVersion` menor ou igual ao já aplicado é ignorado, o que torna a projeção idempotente e tolerante a reentrega.

5. EDA: eventos

Envelope

Campo	Descrição
`eventId`	UUID único; chave de idempotência dos consumidores.
`type`	Nome do evento, no passado (`EssaySubmitted`).
`version`	Versão do esquema do evento.
`occurredAt`	Instante do fato, em ISO 8601 UTC.
`aggregateId` e `aggregateVersion`	Agregado de origem e sua versão após o fato.
`correlationId`	`commandId` que originou a cadeia de eventos.
`causationId`	Id da mensagem que causou este evento.
`payload`	Dados do fato.

Garantias

- Entrega pelo menos uma vez (at-least-once): todo consumidor é idempotente por `eventId` .
- A ordem só é garantida por agregado, e é verificada pela versão do agregado (§4), não pela fila.
- Esquemas de evento só mudam de forma compatível; uma mudança incompatível cria uma nova `version` .

Catálogo inicial

O catálogo deriva dos fluxos descritos no pedido de arquitetura. Um evento novo só existe depois de entrar nesta tabela.

Evento	Produzido por	Consumido por
`QuestionAnswered`	Comando `AnswerQuestion`	Projetor de desempenho
`RoutineProgressRecorded`	Comando `RecordRoutineProgress`	Projetor de rotina e de desempenho
`EssaySubmitted`	Comando `SubmitEssay`	Worker `essay-correction`
`EssayCorrected`	Worker `essay-correction`	Projetor de redações e canal de eventos do app
`EssayCorrectionFailed`	Worker `essay-correction`	Projetor de redações e canal de eventos do app
`MockExamCompleted`	Comando `CompleteMockExam`	Worker `mock-exam-processing`
`MockExamProcessed`	Worker `mock-exam-processing`	Projetor de desempenho e canal de eventos do app

Os comandos acima formam o conjunto inicial: `AnswerQuestion`, `RecordRoutineProgress`, `SubmitEssay` e `CompleteMockExam`. As consultas iniciais são as de leitura de desempenho, evolução, histórico de simulados e estado/resultado de uma redação. Seus campos serão definidos em `contracts/` com aprovação.

6. Mensageria: BullMQ + Redis

Filas

Fila	Conteúdo	Consumidor
`essay-correction`	Correção de redações pela IA.	`backend/src/workers/essay-correction`
`mock-exam-processing`	Processamento de simulados concluídos.	`backend/src/workers/mock-exam-processing`
`projections`	Eventos que atualizam modelos de leitura.	`backend/src/workers/projections`
`dead-letter`	Mensagens que esgotaram as tentativas ou falharam de forma permanente.	Reprocesso manual e alerta

Nomes de fila usam kebab-case. Uma fila nova entra nesta tabela antes de existir no código.

Contrato do job

- `name`: tipo do comando ou do evento; `data`: envelope do §5.
- `jobId` determinístico (`<type>_<aggregateId>_<commandId>`), que faz o BullMQ ignorar a publicação duplicada enquanto o job existir.
- O `jobId` não basta para idempotência, porque jobs concluídos podem ser removidos. Cada consumidor registra os `eventId` já processados no banco, na mesma transação do efeito.

Tentativas, falhas e limites

- Falhas transitórias (timeout, `429`, `5xx` da IA, indisponibilidade de banco): nova tentativa com backoff exponencial. O número de tentativas e o atraso inicial são configuração do Worker; os valores iniciais serão definidos na implementação e confirmados por teste de carga.
- Falhas permanentes (payload inválido, conteúdo rejeitado, saída da IA fora do esquema depois das tentativas): o Worker sinaliza falha não recuperável, publica o evento `...Failed` e copia a mensagem para `dead-letter` com o contexto do erro.
- A cópia para `dead-letter` é um passo explícito do tratamento de falha final do Worker; não depende de recurso específico da versão do BullMQ.
- `concurrency` e `limiter` por Worker respeitam o limite de taxa e o custo do provedor de IA.
- Jobs travados (stalled) são reentregues pelo BullMQ; por isso todo handler é idempotente.

Durabilidade do Redis

- Instância dedicada ao BullMQ, com persistência AOF habilitada e política de memória `noeviction`.
- Mesmo com perda de dados no Redis, o outbox transacional (D5) republica o que não foi concluído.

Observabilidade

- Todo log e job carrega `correlationId` (`commandId`).
- Métricas mínimas por fila: profundidade, idade do job mais antigo, latência de processamento e taxa de falha. O alerta mais importante é o crescimento de `dead-letter`.

Porta única

`application/ports` define `QueuePort` (publicar e consumir mensagens do §5). O adaptador BullMQ fica em `infrastructure/queue`. SQS (com SNS para fan-out) e RabbitMQ são implementações alternativas da mesma porta; trocar de tecnologia não altera `domain/` nem `application/`.

7. Workers e integração com a IA

- Um Worker é um processo separado, sem servidor HTTP, que consome uma fila. Escala horizontalmente e tem `concurrency` própria.
- Workers são montados nas composition roots de `backend/src/bootstrap`, que ligam portas a adaptadores.

Pipeline de correção de redação

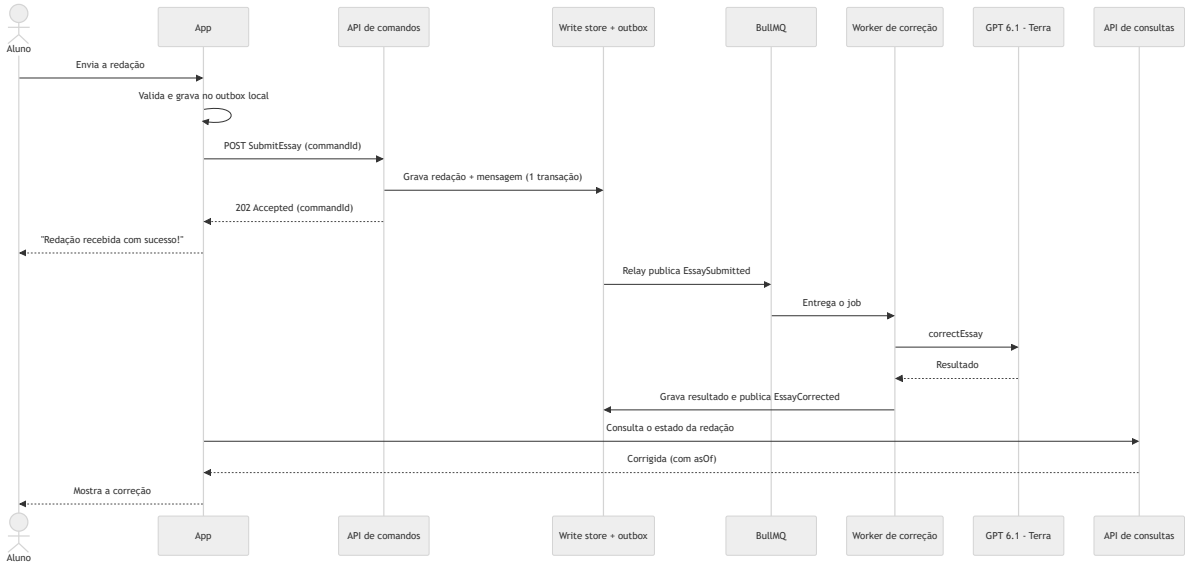
1. O Worker consome `EssaySubmitted` e carrega a redação.
2. Chama `AiPort.correctEssay`, com tempo limite próprio.
3. Valida a saída da IA contra o esquema antes de persistir qualquer resultado.
4. Grava o resultado e publica `EssayCorrected` (ou `EssayCorrectionFailed`).
5. O projetor atualiza o read store e o canal de eventos avisa o app.

Regras para a IA

- O modelo informado é GPT 6.1 - Terra. A página de preços da OpenAI o lista como `gpt-6.1-terra`; o identificador é configuração do servidor e deve ser confirmado na documentação da API antes da implementação (§14).
- Preços por 1 milhão de tokens (padrão): entrada US$ 1,00, entrada em cache US$ 0,05, saída US$ 5,00, gravação em cache de 30 min US$ 1,25 e de 12 h US$ 2,50. As estimativas de custo por mil usuários estão nos guias (§15).
- A chave de API existe só no servidor, fora do repositório, e nunca no app.
- Prompts são versionados em `backend/src/infrastructure/ai/prompts`; o resultado registra `promptVersion` e o modelo usado, para auditoria.
- A interface nunca mostra a saída bruta da IA nem detalhes de erro do provedor; em falha, mostra uma mensagem compreensível e a ação de recuperação.
- O texto do aluno só trafega do servidor para o provedor, com o mínimo de dados necessário.

8. Fluxos principais

8.1 Envio de redação



No passo `POST SubmitEssay`, a API valida identidade, plano Premium e cota (§4) antes de gravar. Se alguma validação falhar, responde `403` e o app mostra a mensagem correspondente em vez de "Redação recebida com sucesso!"; a confirmação só aparece depois do `202`.

8.2 Conclusão de simulado longo

Mesmo padrão do §8.1, com o comando `CompleteMockExam`, a fila `mock-exam-processing` e os eventos `MockExamCompleted` e `MockExamProcessed`. O app responde na hora com a confirmação de recebimento; o desempenho consolidado aparece quando a projeção é aplicada.

8.3 Resposta de questão e progresso da rotina

Comandos `AnswerQuestion` e `RecordRoutineProgress` seguem o fluxo de escrita rápida: gravação no write store, `202` imediato e atualização das estatísticas pela fila `projections`. Não há chamada de IA.

8.4 Consulta de estatísticas

A consulta vai direto à API de consultas e lê o read store. Não passa por comando, fila nem Worker. A resposta traz `asOf`.

9. Aplicativo móvel

Camadas do cliente

`ui` → `commands` e `queries` → `core`. A interface nunca chama a rede diretamente: comandos passam pelo outbox e consultas pelo cliente de `core/api`.

Outbox local

- Todo comando é gravado no outbox local antes do envio e só sai de lá quando a API responde `202`.

- Sem conexão, o comando permanece pendente e é reenviado com o mesmo `commandId`.
- O mecanismo de persistência local depende de dependência a aprovar (§14).

Estados de um comando na interface

Estado	Significado	Texto e ação de recuperação
`queued-locally`	Gravado no outbox, ainda não enviado.	Informar que será enviado quando houver conexão.
`sending`	Envio em andamento.	Indicador de carregamento; sem ação duplicada.
`received`	A API respondeu `202`.	Confirmação de recebimento (por exemplo, "Redação recebida com sucesso!").
`processing`	Worker em execução.	Informar que o processamento está em andamento.
`completed`	Evento de conclusão aplicado na projeção.	Mostrar o resultado.
`failed`	Evento `...Failed` ou rejeição permanente.	Mensagem compreensível e ação de reenviar.

- Todo estado é comunicado por texto, nunca só por cor ou ícone, e mudanças relevantes são anunciadas por tecnologia assistiva.
- Consultas guardam o `asOf` da resposta e são invalidadas quando chega um evento relacionado; se o canal de eventos estiver indisponível, usam polling com intervalo crescente.

10. Organização de diretórios

10.1 Estrutura alvo

```
Aprova.AI/
├── index.ts                    # Entrada do Expo (registerRootComponent); é o `main` do package.json
├── app.json
├── eas.json                    # Perfis do EAS Build (nasce quando o primeiro build for configurado)
├── package.json
├── tsconfig.json
├── assets/                     # Ícones e imagens
├── contracts/                  # Contrato app <-> backend: tipos, sem lógica
│   ├── commands/               # *.command.ts
│   ├── queries/                # *.query.ts (pedido e DTO de resposta)
│   └── events/                 # *.event.ts e envelope
├── src/                        # Aplicativo móvel (Expo)
│   ├── app/                    # Composição: App.tsx, providers, navegação
│   ├── features/<contexto>/    # questions, routine, mock-exams, essay, performance
│   │   ├── commands/           # Intenções do aluno -> outbox -> API de comandos
│   │   ├── queries/            # Leituras: hooks e mapeadores de DTO
│   │   ├── events/             # Reação a eventos recebidos
│   │   └── ui/                 # Telas e componentes exclusivos do contexto
│   ├── core/                   # Infraestrutura do cliente, sem regra de negócio
│   │   ├── api/                # Cliente HTTP de comandos e consultas
│   │   ├── outbox/             # Fila local de comandos pendentes
│   │   ├── storage/            # Persistência local
│   │   └── events/             # Canal de eventos do servidor
│   ├── components/             # UI compartilhada (*.web.tsx ao lado do nativo)
│   ├── hooks/                  # Hooks compartilhados
│   └── constants/              # Tokens visuais (theme.ts)
├── backend/                    # API de comandos e consultas + Workers
│   └── src/
│       ├── domain/             # Agregados, eventos de domínio e regras (puro)
│       ├── application/
│       │   ├── commands/       # Handlers de comando
│       │   ├── queries/        # Handlers de consulta
│       │   ├── events/         # Projetores e reações a eventos
│       │   └── ports/          # QueuePort, AiPort, repositórios, relógio
│       ├── infrastructure/
│       │   ├── queue/          # Adaptador BullMQ (e alternativas)
│       │   ├── persistence/    # Write store, read store e outbox
│       │   └── ai/             # Adaptador GPT 6.1 - Terra e prompts versionados
│       ├── api/                # HTTP: rotas de comando e rotas de consulta, separadas
│       ├── workers/            # Um processador BullMQ por fila
│       └── bootstrap/          # Composition roots: api.ts e worker.ts
├── infra/                      # Implantação: Docker Compose, Caddyfile e scripts (nasce no primeiro
uso)
├── .github/workflows/          # Integração e entrega contínuas (nasce no primeiro uso)
├── docs/                       # Documentação (ARQUITETURA, guias de implementação, design)
```

```
├── .claude/ e .agents/         # Regras e workflows para assistência ao desenvolvimento
└── README.md
```

Contextos iniciais de `features/` (glossário português → pasta): questões → `questions`, rotina → `routine`, simulados → `mock-exams`, redação → `essay`, desempenho → `performance`. Um contexto novo só nasce com um comando, uma consulta ou uma tela real.

10.2 O que existe e o que nasce no primeiro uso

Para não criar pastas vazias nem abstrações sem uso, o repositório contém hoje apenas as camadas, cada uma com um `README.md` de uma página (responsabilidade e limites de importação). Subpastas e arquivos de código surgem junto com o primeiro uso real:

Já existe	Nasce no primeiro uso
`index.ts`, `src/app/`	`src/components/`, `src/hooks/`, `src/constants/theme.ts`
`contracts/`, `src/features/`, `src/core/` (README)	Subpastas de `contracts/`, de `src/core/` e de cada contexto
`backend/` com `package.json`, migrações, testes e o código de todas as camadas (marcos B0 a B4; estado em `docs/IMPLEMENTACAO-BACKEND.md`, §21); `contracts/commands`, `queries`, `events` e `auth`	`backend/src/workers/mock-exam-processing` e `notifications`, `infra/`, `.github/workflows/`, `eas.json`

10.3 Regras de dependência

Camada	Pode importar	Não pode importar
`src/app`	`features/*`, `core`, `components`, `hooks`, `constants`	—
`src/features/<contexto>`	`core`, `components`, `hooks`, `constants`, `contracts`	Outro contexto; `app`
`src/core`	`contracts`	`features`, `app`, `components`
`src/components`	`hooks`, `constants`	`features`, `core`, `app`
`src/hooks`, `src/constants`	`constants`	`features`, `core`, `app`, `components`
`contracts`	Apenas arquivos de `contracts`	`src`, `backend`
`backend/src/domain`	Nada além de si	Todo o restante
`backend/src/application`	`domain`, `contracts`	`infrastructure`, `api`, `workers`, bibliotecas de fila, IA ou banco
`backend/src/infrastructure`	`application/ports`, `domain`, `contracts`	`api`, `workers`
`backend/src/api`	`application`, `contracts`	`infrastructure`, `domain`
`backend/src/workers`	`application`, `contracts`	`infrastructure`, `api`
`backend/src/bootstrap`	Todas as camadas	—

Contextos do app se comunicam por eventos e contratos, nunca importando uns aos outros. Handlers de consulta só leem o read store; handlers de comando só gravam no write store e no outbox.

10.4 Convenções

- Pastas em kebab-case; um arquivo, uma responsabilidade.
- Sufixos por papel: `*.command.ts`, `*.query.ts`, `*.event.ts`, `*.handler.ts`, `*.projector.ts`, `*.worker.ts`, `*.port.ts`, `*.adapter.ts`.
- Tipos ficam junto do único consumidor. Um tipo usado pelo app e pelo backend vai para `contracts/` (a segunda utilização real).
- `contracts/` só tem tipos, sem código executável. Valores de negócio, como o limite de correções por mês, são configuração do servidor e chegam ao app por consulta. A validação em tempo de execução fica no backend (§14).
- Arquivos específicos de plataforma (`*.web.tsx`) ficam ao lado do arquivo nativo.
- Não há barramento genérico de comandos ou consultas: rotas e telas chamam o handler diretamente. Um barramento só entra quando houver necessidade real (por exemplo, middleware comum).
- O alias `@/` (para `src/`) e quaisquer outros aliases entram no `tsconfig.json` junto do primeiro uso; hoje não há aliases configurados.
- Enquanto o Expo Router não for aprovado, `src/app/` contém a composição do app. Se for aprovado, esta seção registra para onde a composição migra, porque `src/app/` passa a conter somente rotas.
- Quando `backend/package.json` existir, o `tsconfig.json` da raiz passa a excluir `backend/`, que terá o seu.
- `infra/` e `.github/workflows/` contêm só configuração e scripts, nunca regra de negócio nem segredos.

10.5 Onde colocar cada coisa

Preciso de...	**Local**
Um novo comando do aluno	`contracts/commands` + `src/features/<contexto>/commands` + `backend/src/application/commands`
Uma nova leitura ou gráfico	`contracts/queries` + `src/features/<contexto>/queries` + `backend/src/application/queries`
Um novo evento	Catálogo do §5, `contracts/events`, produtor e consumidores
Uma nova fila ou Worker	Tabela do §6 e `backend/src/workers`
Chamar a IA	`AiPort` em `application/ports`; adaptador em `infrastructure/ai`
Uma tela de um contexto	`src/features/<contexto>/ui`
Um componente usado por vários contextos	`src/components`

10.6 Refatoração aplicada

Antes	Depois	Motivo
`src/app/index.ts`	`index.ts` (raiz)	O `package.json` declara `main: "index.ts"`, arquivo que não existia na raiz; mover corrige a entrada e reserva `src/app/` para composição ou rotas. O import passa a `./src/app/App`.
`src/app/App.tsx`	Sem mudança	Já está na camada de composição.
—	`contracts/`, `src/features/`, `src/core/` com `README.md`	Camadas do cliente e do contrato.
—	`backend/src/{domain,application,infrastructure,api,workers,bootstrap}` com `README.md`	Camadas de API e Workers.

11. Resiliência e segurança

Nenhuma atividade em segundo plano se perde porque há cinco proteções em camadas: outbox local, idempotência por `commandId`, outbox transacional, tentativas do BullMQ com Redis persistente e `dead-letter` com reprocesso.

Cenário	Comportamento
App sem conexão	O comando fica no outbox local e é reenviado com o mesmo `commandId`.
API grava, mas a resposta se perde	O app reenvia; a API reconhece o `commandId` e devolve o mesmo `202`.
Redis indisponível	A API continua aceitando comandos (outbox transacional); o relay publica quando o Redis voltar.
Relay cai entre gravar e publicar	A mensagem segue pendente no outbox e é publicada depois; uma duplicata é absorvida pela idempotência dos consumidores.
Worker cai durante um job	O job travado é reentregue; o handler é idempotente.
Timeout ou `429` da IA	Nova tentativa com backoff; `limiter` e `concurrency` reduzem a pressão.
Saída da IA fora do esquema	Validação falha; depois das tentativas, falha permanente, `...Failed` e `dead-letter`.
Mensagem que sempre falha	Vai para `dead-letter`, gera alerta e aguarda reprocesso manual.
Projeção atrasada	A consulta devolve `asOf` antigo e a interface sinaliza o atraso.

Segurança:

- Segredos e chaves ficam fora do repositório. O `.gitignore` atual cobre `.env*.local`, não `.env`; revise a cobertura antes de introduzir variáveis de ambiente.

- O repositório é público: nada sensível entra nele nem nos logs da integração contínua.
- Todo dado é validado na borda: comando, consulta, evento e saída da IA.
- Erros mostrados ao aluno não expõem identificadores, tokens nem payloads de falha.
- A identidade do aluno e a política de dados pessoais (LGPD) estão em aberto (§14); nenhum comando ou consulta é implementado sem definir a quem o dado pertence.

12. Testes e validação

- Estado atual: o `backend/` tem Vitest e os scripts `typecheck`, `lint` e `test` (testes unitários, de API e de integração com Postgres e Redis reais, estes últimos só com `TEST_DATABASE_URL` e `TEST_REDIS_URL`). O app na raiz ainda não tem executor de testes nem scripts de lint ou de tipos; nele, a verificação de tipos é manual (`npx tsc --noEmit`).
- Quando um executor de testes for aprovado: testes unitários de `domain`, handlers e projetores; testes de contrato entre `contracts/` e a API; teste de integração com BullMQ e um Redis efêmero; teste de ponta a ponta do fluxo do §8.1.
- Toda nova fronteira (comando, consulta, evento, saída da IA) é testada nos casos de sucesso, inválido, ausente e falha.

13. Governança dos documentos

Documento	Responsabilidade
`docs/ARQUITETURA.md` e `docs/ARQUITETURA.pdf`	Arquitetura, decisões, contratos e organização de diretórios.
`docs/AGENTS.md`	Regras compartilhadas dos agentes.
`docs/Claude.md` e `docs/CLAUDE.local.md`	Guia operacional e preferências locais.
`docs/Codex.md`	Resumo para o Codex.
`docs/DESIGN.md` e `docs/DesignIA_Regras.md`	Design, interface e checklist contra aparência genérica.
`docs/IMPLEMENTACAO-FRONTEND.md`, `docs/IMPLEMENTACAO-BACKEND.md`, `docs/IMPLEMENTACAO-DEVOPS.md` e os PDFs correspondentes	Guias de implementação por equipe, derivados deste documento.
`README.md`	Visão geral, comandos e árvore de arquivos.
`.claude/` e `.agents/`	Regras, comandos, skills e agentes.

Ao mudar uma decisão ou a estrutura:

1. Atualize `docs/ARQUITETURA.md`.
2. Atualize a árvore e o estado atual no `README.md`.
3. Atualize os guias (`AGENTS.md`, `Claude.md`, `Codex.md`) e as regras em `.claude/` e `.agents/` que citem o que mudou.
4. Regenere `docs/ARQUITETURA.pdf` e os PDFs dos guias de implementação afetados.
5. Faça um commit por assunto, no padrão `(tipo): Frase no passado`, como em `(docs): Adicionado README.md completo e estruturado desta fase inicial`.

14. Decisões em aberto

Cada item abaixo exige decisão antes de qualquer implementação que dependa dele. A coluna Status indica o que já está decidido e o que os guias de implementação apenas propõem; proposta não autoriza instalar dependência nem criar infraestrutura.

Decisão	Impacto	Status
Autenticação e identidade do aluno	Todo comando, consulta e evento precisa pertencer a um aluno.	Decidido: login com Google e Apple (OIDC), JWT de acesso curto e refresh token rotativo emitidos pela API.
Banco do write store e do read store	Modelagem de agregados, projeções e outbox.	Decidido: PostgreSQL com esquemas `write` e `read` na mesma instância.
Runtime e framework do backend	Estrutura de `backend/package.json` e de `api/`.	Decidido: Node.js 24 LTS, Fastify, Drizzle ORM, BullMQ, Vitest.
Hospedagem do Redis e dos Workers	Persistência AOF, alertas e escala.	Decidido (D11): Oracle Always Free com Docker Compose; Render depois.
Canal de eventos para o app	Como o app descobre `EssayCorrected` e `MockExamProcessed`.	Proposta: consulta periódica com intervalo crescente, com push do Expo como aviso; aguarda aprovação.
Persistência local do app (outbox)	Dependência nova no app.	Proposta: `expo-sqlite`; aguarda aprovação.
Biblioteca de validação em tempo de execução	Esquemas de validação e o impacto em D7.	Proposta: `zod` somente no backend, com `contracts/` só de tipos (o esquema do backend é verificado contra o tipo com `satisfies`), o que preserva D7. Decidido.
Expo Router e biblioteca de dados do cliente	Onde fica a composição de `src/app/` (§10.4).	Proposta: Expo Router e TanStack Query; aguarda aprovação.
Contrato exato do GPT 6.1 - Terra	`AiPort`, limites de taxa e prompts.	Parcial: identificador e preços confirmados; limites de contexto e de saída e formato de saída em aberto.
Rubrica de correção de redação e regras de simulado	Esquema do resultado da IA e dos eventos.	Em aberto (produto).
Fonte do plano Premium (assinatura, cobrança, preço, período de teste)	Implementação real de `EntitlementPort` e custos de loja.	Em aberto; custos estimados nos guias.
Janela da cota de redação (mês corrido ou 30 dias móveis)	Regra de `SubmitEssay` e texto da interface.	Premissa: mês corrido em `America/Sao_Paulo`; confirmar com o produto.
Exceção: `GetEntitlements` lê o write store pela `EntitlementPort`	O plano e a cota precisam ser exatos; a alternativa são os eventos `PlanChanged` e `UserRegistered` mais uma projeção.	Decidido: a exceção foi aprovada.
Comando `RegisterPushToken`, consulta `GetEssayList` e fila `notifications`	Catálogos de comandos e consultas (§4) e de filas (§6), para o push e o histórico de redações.	Propostas; só entram nas tabelas desta arquitetura depois de aprovadas.
LGPD: base legal, retenção e exclusão	Dados enviados à IA e guardados no servidor.	Em aberto.

Decisão	Impacto	Status
Executor de testes e integração contínua	Seção 12.	Decidido para o backend: Vitest e scripts `lint` e `typecheck` em `backend/`. Proposta para o app (`jest-expo`) e para a integração contínua (GitHub Actions); aguardam aprovação.

15. Guias de implementação

Cada equipe tem um guia que reúne tudo o que é preciso para implementar sua parte, derivado deste documento. Em caso de divergência, este documento prevalece e o guia deve ser corrigido.

Guia	Público	Arquivos
Implementação Front-End	Equipe do app Expo	`docs/IMPLEMENTACAO-FRONTEND.md` e `.pdf`
Implementação Back-End	Equipe de API, Workers e dados	`docs/IMPLEMENTACAO-BACKEND.md` e `.pdf`
Implementação DevOps	Equipe de infraestrutura, CI/CD e operação	`docs/IMPLEMENTACAO-DEVOPS.md` e `.pdf`